



UNIVERSIDAD DEL BÍO-BÍO

Universidad del Bío-Bío
Facultad de Ciencias
Ingeniería Estadística

Evaluación 2: Procesamiento y Consolidación de Datos de Matrícula en Educación Superior (2020-2024)

Docente:
Luis Gómez

Alumno:
Francisca Pacheco

Ciencia de Datos en la Terminal Linux 220317

28 de diciembre de 2025

Índice de Contenidos

Índice

Índice de Tablas	1
1. Introducción	2
2. Obtención y Preparación de Datos	2
2.1. Carga de datos	2
2.2. Filtrado inicial de carreras	2
2.3. Limpieza y estandarización de variables	2
3. Reestructuración de los Datos	2
3.1. Agregación de matrícula	2
3.2. Pivoteo a formato ancho	3
4. Conjunto de Datos Final	3
5. Análisis de Resultados	3
5.1. Instituciones con mayor presencia (Oferta Académica)	3
5.2. Instituciones con mayor impacto (Volumen de Matrícula)	3
6. Reproducibilidad del Proceso	4
7. Conclusiones	4

Índice de cuadros

1. Muestra representativa de ies_last_5_years_data.csv	3
--	---

1. Introducción

El presente informe documenta el proceso de limpieza, transformación y reestructuración de datos de educación superior en Chile, enfocado en carreras relacionadas con Estadística y Ciencia de Datos.

Una consultora educativa requiere analizar la evolución de la matrícula total y de primer año durante el período 2020-2024, con el fin de evaluar tendencias en la oferta académica y la demanda estudiantil en este ámbito disciplinar.

Para cumplir este objetivo, se procesó el archivo `estudio_mercado_ordenado.csv` utilizando el entorno de línea de comandos Nushell y su plugin Polars. Todas las etapas del análisis fueron automatizadas mediante un script reproducible (`script.nu`), generando un conjunto de datos final limpio y estructurado para análisis posteriores.

2. Obtención y Preparación de Datos

2.1. Carga de datos

El análisis comenzó con la lectura del archivo fuente, que contiene información histórica sobre matrícula, instituciones, sedes y carreras de educación superior.

La lectura se realizó mediante el comando:

```
let df = open estudio_mercado_ordenado.csv
```

El archivo fue cargado como una tabla estructurada, permitiendo la manipulación directa de columnas y registros.

2.2. Filtrado inicial de carreras

Se filtraron solo las carreras pertinentes para el análisis:

- Se incluyeron programas cuyos nombres contienen “estad” o “dato”, sin distinción de mayúsculas/minúsculas. - Se excluyeron programas no relevantes como licenciaturas sin título profesional, magísteres, doctorados, diplomados, postítulos, pedagogías, programas de regularización y menciones específicas irrelevantes.

El comando utilizado fue:

```
let incluye = "(?i)estad|dato"
let excluye = "(?i)licenciatura|magister|doctorado|diplomado|postitulo|pedagogia|redes|salud"
let df_filtrado = $df | polars filter (
  (polars col "NOMBRE CARRERA" | polars contains $incluye) and
  not (polars col "NOMBRE CARRERA" | polars contains $excluye)
)
```

Este filtrado resultó en **X carreras relevantes** (indicar el número exacto con ‘shape’).

2.3. Limpieza y estandarización de variables

La columna AÑO contenía prefijos textuales (ej. “MAT_2020”) que impedían tratar el año como un número. Se realizaron las siguientes operaciones:

```
let df_limpio = $df_filtrado | polars with-column (
  polars col "AÑO"
  | polars str-replace --pattern "MAT_" --replace ""
  | polars cast i64
  | polars as "AÑO"
)
```

Esto permitió convertir el año a tipo entero y mantener consistencia en los nombres de instituciones, sedes y carreras.

3. Reestructuración de los Datos

3.1. Agregación de matrícula

Dado que el conjunto original estaba en formato largo (una fila por carrera y año), se sumaron las métricas:

- TOTAL MATRICULADOS - TOTAL MATRICULADOS PRIMER AÑO

por cada combinación de NOMBRE INSTITUCIÓN, NOMBRE SEDE, NOMBRE CARRERA y AÑO, mediante:

```
let df_agrupado = $df_limpio | polars group-by ["NOMBRE INSTITUCIÓN" "NOMBRE SEDE" "NOMBRE CARRERA"] |
  (polars col "TOTAL MATRICULADOS" | polars sum | polars as "T"),
  (polars col "TOTAL MATRICULADOS PRIMER AÑO" | polars sum | polars as "P")
]
```

3.2. Pivoteo a formato ancho

Se transformó el formato de largo a ancho para que cada año se convirtiera en columna independiente por cada métrica:

```
let df_pivoted = $df_agrupado | polars collect | polars pivot --index ["NOMBRE INSTITUCIÓN" "NOMBRE SEDE"]
```

El resultado es un dataframe con filas únicas por carrera y columnas para cada combinación de métrica y año (T'2020, P'2020, etc.).

4. Conjunto de Datos Final

El dataset final contiene todas las carreras filtradas y métricas de matrícula total (T) y primer año (P) desde 2020 a 2024, listo para análisis posteriores.

Inst.	Sede	Carrera	T'20	T'21	T'22	T'23	T'24	P'20	P'21	P'22	P'23	P'24
IP ESC. COMERCIO	SANTIAGO	ING. CIENCIAS DE DATOS	-	6	4	65	-	-	6	2	61	-
IP IPG	PROVIDENCIA	ING. CIENCIA DE DATOS	-	-	-	-	4	-	-	-	-	4
IP IPG	PROVIDENCIA	TNS CIENCIAS DE DATOS	-	-	-	-	2	-	-	-	-	2
IP PROVIDENCIA	V. MACKENNA	TNS CIENCIA DE DATOS	-	25	80	109	-	-	25	67	73	-
PUC CHILE	SAN JOAQUIN	MATEM./ESTADISTICA	73	45	24	11	3	0	0	0	0	0
PUC CHILE	SAN JOAQUIN	ESTADISTICA	103	137	177	192	220	41	41	42	44	44
PUC VALP	CASA CENTRAL	ESTADISTICA	44	33	22	11	8	0	0	0	0	0
PUC VALP	CASA CENTRAL	ING. ESTADISTICA	24	37	41	34	32	24	17	11	0	0
PUC VALP	CASA CENTRAL	IC EN CIENCIA DE DATOS	-	19	46	61	94	-	19	23	28	39
UCM	CASA CENTRAL	ING. EN ESTADISTICA	71	93	99	105	113	44	25	13	18	21

Cuadro 1: Muestra representativa de ies_last_5_years_data.csv

5. Análisis de Resultados

Tras el proceso de filtrado y consolidación de datos, se obtuvo un conjunto de datos final con **32 programas académicos** únicos que cumplen con los criterios disciplinares en el área de Estadística y Ciencia de Datos para el periodo 2020-2024.

5.1. Instituciones con mayor presencia (Oferta Académica)

Al evaluar la presencia desde el punto de vista de la cantidad de sedes y programas ofrecidos, destacan las siguientes instituciones:

- **IP AIEP:** Es la institución con mayor presencia territorial en el área técnica, con **7 programas distintos** distribuidos en sedes como Bellavista, Barrio Universitario, Online, Puerto Montt y su Campus Virtual. Su oferta principal es el *Técnico en Análisis de Datos*, que muestra una fuerte expansión en su modalidad online hacia 2024.
- **Universidad de Santiago de Chile (USACH):** Presenta una sólida oferta profesional con **3 programas**, incluyendo *Ingeniería Estadística* y *Astrofísica con mención en Ciencia de Datos*.
- **Pontificia Universidad Católica de Chile (PUC):** Concentra su presencia en el Campus San Joaquín con **2 programas** fundamentales: *Estadística* y el programa conjunto *Matemática/Estadística*.
- **Pontificia Universidad Católica de Valparaíso (PUCV):** Cuenta con **3 registros**, destacando su transición hacia la *Ingeniería Civil en Ciencia de Datos*.

5.2. Instituciones con mayor impacto (Volumen de Matrícula)

Si definimos la presencia por el volumen de alumnos matriculados, los datos revelan liderazgos claros:

- **Dominio en Matrícula Total:** La carrera de *Estadística* en la PUC (San Joaquín) posee la mayor matrícula del conjunto, alcanzando los **220 alumnos totales en 2024**, tras un crecimiento constante desde los 103 alumnos en 2020.

- **Crecimiento en Ciencia de Datos:** La *Ingeniería Civil en Ciencia de Datos* de la PUCV muestra un crecimiento del 394 %, pasando de 19 alumnos en 2021 a **94 alumnos en 2024**.
- **Expansión del Nivel Técnico:** El programa online de *IP AIEP (Técnico en Análisis de Datos)* irrumpe con fuerza en 2023-2024, alcanzando una matrícula de primer año de 72 alumnos en su último periodo reportado.
- **Tendencia de Nuevos Actores:** Instituciones como *IP IPG*, *IP Escuela de Comercio de Santiago* e *IP IACC* han introducido programas de Ciencia de Datos entre 2023 y 2024, evidenciando una rápida diversificación de la oferta para satisfacer la demanda del mercado laboral.

6. Reproducibilidad del Proceso

La arquitectura del proyecto fue diseñada bajo el principio de “Infraestructura como Código”, donde el script `script.nu` actúa como el motor de ejecución, garantizando que cualquier tercero pueda obtener exactamente los mismos resultados.

Para reproducir el archivo de salida `ies_last_5_years_data.csv`, se deben seguir estos pasos en un entorno Linux con Nushell instalado:

- Preparación:** Asegurar que el archivo fuente `estudio_mercado_ordenado.csv` se encuentre en el mismo directorio que el script.
- Ejecución:** Ejecutar el script desde la terminal utilizando el intérprete de Nushell:

`nu script.nu`
- Validación:** Tras la ejecución, el sistema generará un archivo CSV con 32 registros únicos, estructurados en formato ancho con 10 columnas de métricas (T'20 a T'24 y P'20 a P'24).

7. Conclusiones

El desarrollo de este proceso de preparación y reestructuración de datos permite extraer conclusiones fundamentales tanto a nivel técnico como disciplinar:

- **Eficacia de las herramientas:** La combinación de Nushell y Polars demostró ser altamente eficiente para el manejo de archivos de gran volumen (142MB), permitiendo realizar filtrados complejos y transformaciones de formato (long to wide) con sintaxis legible y tiempos de respuesta mínimos.
- **Tendencias en Educación Superior:** Los resultados procesados revelan un ecosistema dinámico. Mientras que las carreras de Estadística tradicional (como en la PUC) mantienen el mayor volumen de alumnos totales, existe una irrupción acelerada de programas de Ciencia de Datos en instituciones técnicas (IP AIEP) y universidades regionales (PUCV), respondiendo a la demanda de perfiles analíticos modernos.
- **Valor de la Automatización:** Al eliminar la manipulación manual de hojas de cálculo, se garantiza la integridad de los datos. La trazabilidad lograda mediante el control de versiones en Git y la reproducibilidad del script `script.nu` permiten que este flujo de trabajo sea escalable para futuros análisis de matrícula.

El conjunto de datos final constituye una base sólida para el diseño de visualizaciones dinámicas y la toma de decisiones estratégicas en el ámbito de la oferta académica nacional.